FinalEnhanced

Yu-Chen Xue

2018年6月30日

0. 使用 GAM 分析 EnerNOC Dataset 中商用大樓的用電狀況

1. Dataset 介紹:

名稱: EnerNOC GreenButton Data

來源: open enernoc data

https://github.com/PetoLau/petolau.github.io/tree/master/ $_$ rmd/ 簡述: 原始資料集由 EnerNOC 電力公司提供,它依循時間序列記錄了 2012 年 100 棟不記名的建築物每 5 分鐘的用電情況。經過整理後的資料記載了每半個小時的用電狀況,其解釋變數如下

- value: 特定時間點下的電耗值 - week: 週次 - date: 日期

- type: 大樓類型

2. 使用的方法:

Generalized additive model (GAM)

3. 大綱

- 1. 資料集分析
- 2. 模型選擇
- 3. 分析解釋變量的重要情況
- 4. 預測電耗

1. 資料集分析

引入必要的模組

library(feather)

library(data.table)

library(mgcv)

```
## Loading required package: nlme
## This is mgcv 1.8-23. For overview type 'help("mgcv-package")'.

library(car)

## Loading required package: carData

library(ggplot2)

library(dplyr, warn.conflicts = FALSE)
```

讀取資料

```
DT <- as.data.table(read_feather("D:/WORKSPACE/RProjects/EnorNOC-GAM/DT_4_ind"))
str(DT)

## Classes 'data.table' and 'data.frame': 70080 obs. of 5 variables:

## $ date_time: POSIXct, format: "2012-01-02 00:00:00" "2012-01-02 00:30:00" ...

## $ value : num 1590 1564 1560 1585 1604 ...

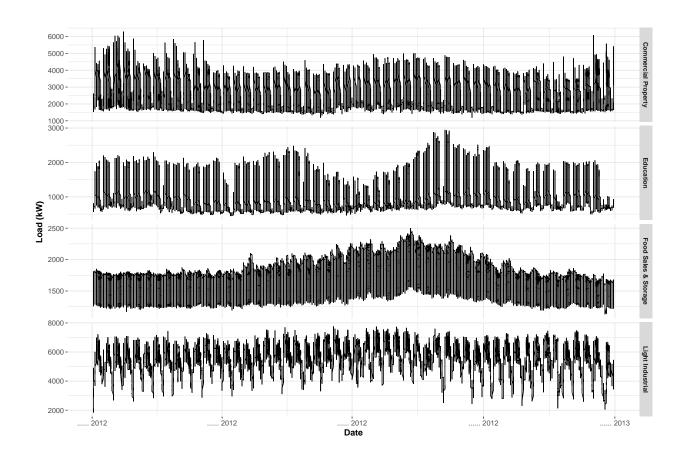
## $ week : chr "Monday" "Monday" "Monday" ...

## $ date : Date, format: "2012-01-02" "2012-01-02" ...

## $ type : chr "Commercial Property" "Commerc
```

畫圖查看資料

```
ggplot(data = DT, aes(x = date, y = value)) +
geom_line() +
facet_grid(type ~ ., scales = "free_y") +
theme(panel.border = element_blank(),
    panel.background = element_blank(),
    panel.grid.minor = element_line(colour = "grey90"),
    panel.grid.major = element_line(colour = "grey90"),
    panel.grid.major.x = element_line(colour = "grey90"),
    axis.text = element_text(size = 10),
    axis.title = element_text(size = 12, face = "bold"),
    strip.text = element_text(size = 9, face = "bold")) +
labs(x = "Date", y = "Load (kW)")
```



可以看出 Food Sales & Storage 這一類的用電情況不隨工作日/雙休日而變化

為了方便描述電耗與週次的關係,這裡使用 package car 中的 function record, 新增一個 欄位,記載週次所對應的數字

```
DT[, week_num := as.integer(car::recode(week,
    "'Monday'='1';'Tuesday'='2';'Wednesday'='3';'Thursday'='4';
    'Friday'='5';'Saturday'='6';'Sunday'='7'"))]
unique(DT[, week])

## [1] "Monday" "Tuesday" "Wednesday" "Thursday" "Friday" "Saturday"
## [7] "Sunday"

unique(DT[, week_num])
```

從讀取的資料中獲取 industry, date, weekday and period 等信息,並使用變量來儲存。因為每半個小時觀察一次,所以一天的資料由 48 筆連續的觀察資料組成,因此有 period <-48

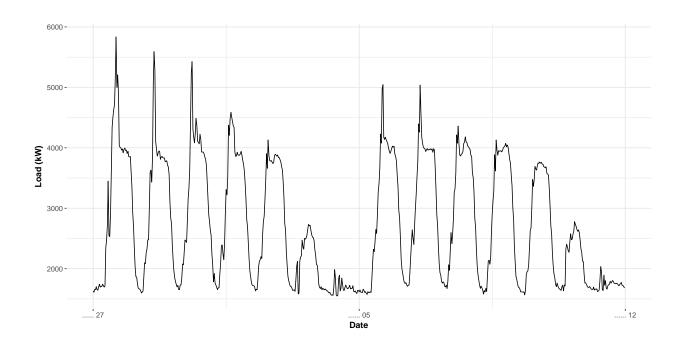
```
n_type <- unique(DT[, type])
n_date <- unique(DT[, date])
n_weekdays <- unique(DT[, week])
period <- 48</pre>
```

截取兩個禮拜內的商業用樓房的電耗記錄,並儲存在 data_r 變量中。之後畫圖展示之。

type == n_type[1] 表示 "Commercial Property", date %in% n_date[57:70] 表示兩個禮拜

```
data_r <- DT[(type == n_type[1] & date %in% n_date[57:70])]

ggplot(data_r, aes(date_time, value)) +
    geom_line() +
    theme(panel.border = element_blank(),
        panel.background = element_blank(),
        panel.grid.minor = element_line(colour = "grey90"),
        panel.grid.major = element_line(colour = "grey90"),
        panel.grid.major.x = element_line(colour = "grey90"),
        axis.text = element_text(size = 10),
        axis.title = element_text(size = 12, face = "bold")) +
    labs(x = "Date", y = "Load (kW)")</pre>
```



根據每天的週期性變化和每週的週期性變化, 重新構建資料

```
##
          Load Daily Weekly
## 1: 1630.875
                          1
## 2: 1611.201
                          1
## 3: 1657.160
                   3
                          1
## 4: 1653.042
                          1
## 5: 1702.316
                   5
                          1
## 6: 1648.411
                          1
```

2. 模型選擇

使用 mgcv 套件包的 gam 函數建立 GAM 模型,其中每天的週期性變化採用 cubic regression spline 模式來描述,每週的週期性變化採用 P-splines 來描述。

查看模型的 summary

```
summary(gam_1)$r.sq

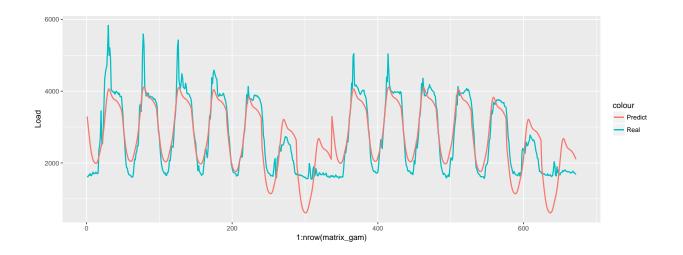
## [1] 0.7718406

summary(gam_1)$sp.criterion

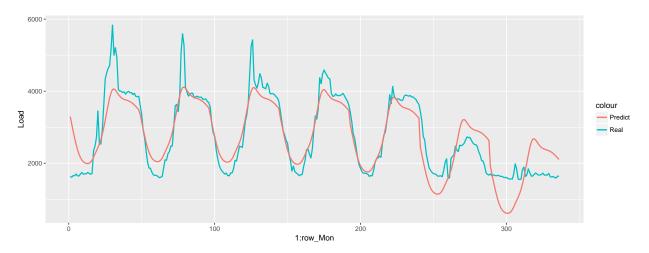
## GCV.Cp
## 245544.9
```

GCV 是表示擬合情況的一個指標,越小說明模型的擬合效果越好。另外可以看出,R-sq 的數值不高,這個模型效果不好

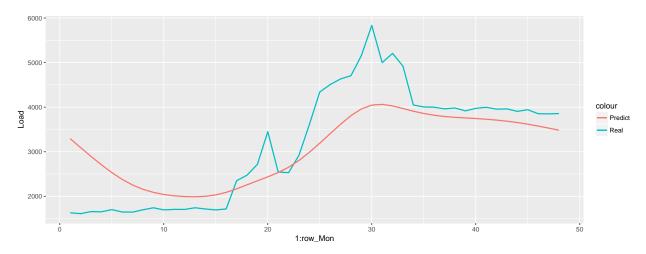
查看這兩個禮拜的用電量的情況實際值與預測值的比較。



看上去狀況並不好, 仔細看第一個禮拜的情況



這個模型只能預測平日用電的趨勢,而具體電耗值卻沒辦法準確預測。在仔細看看禮拜一的用電狀況



問題在於: 這天開始的實際用電量與這天結束時的用電量並不吻合, 然而模型卻給出了一天週期性的預測結果, 這跟實際狀況不一致。因此我們需要換一個思路重建模型。

這回, 我們使用 interaction 的方法, 把 Daily 和 Weekly 同時進行考量, 重建模型,

[1] 0.9352108

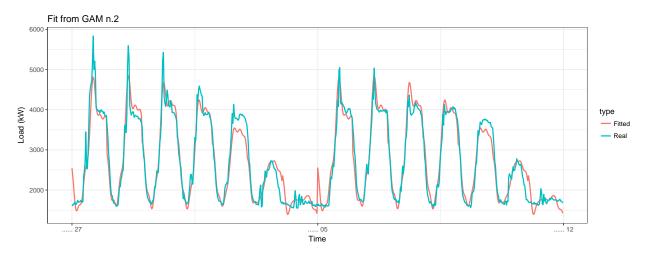
```
summary(gam_2)$sp.criterion
```

```
## GCV.Cp
## 71162.37
```

根據 R.sq 和 p-value 可以看出,這個模型比上一個模型來的更好

畫出這個模型的預測結果和實際結果的比較

```
ggplot(data = datas, aes(date_time, value, group = type, colour = type)) +
  geom_line(size = 0.8) +
  theme_bw() +
  labs(x = "Time", y = "Load (kW)",
     title = "Fit from GAM n.2")
```



這回明顯可以看出: 禮拜一到禮拜四的擬合效果提升了不少

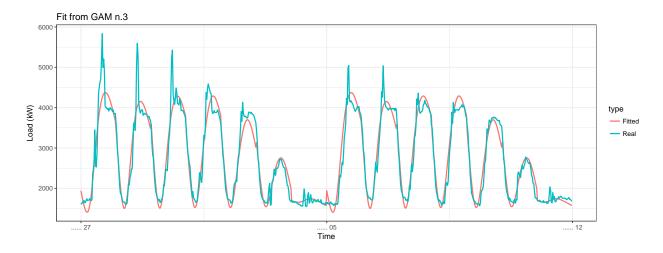
接著使用另一種更進階的 Interaction 方法,這回使用另外一種稱為 "tensor product" 的 smooth function 類型

[1] 0.9268452

```
summary(gam_3)$sp.criterion
```

GCV.Cp ## 79724.9

作圖分析 gam_3



我們還可以做得更好, 比如讓 smooth function 的 knots (類似維度的概念) 更接近每天和每周的週期性情況

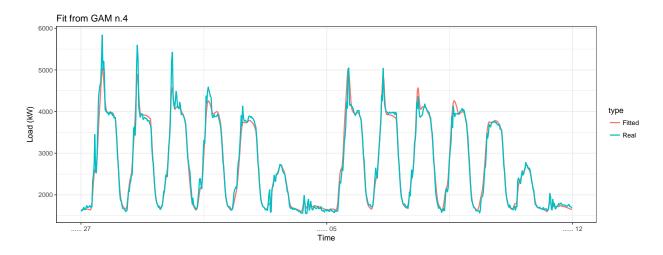
[1] 0.9727604

summary(gam_4)\$sp.criterion

```
## GCV.Cp
## 34839.46
```

可以看見 R-sq 又上升了一點點,關鍵是 edf value 上升了 5 倍之多。

畫出 gam_4 的圖像



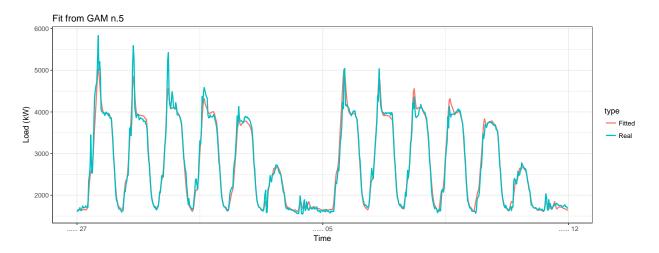
好了,加入我們想要貪婪一點,把前面的一些方法都加進來,結果會怎麼樣呢?這裡構建一個gam_5來驗證一下

[1] 0.9717469

```
summary(gam_5)$sp.criterion
```

GCV.Cp ## 35772.35

雖然 p-value 一樣為 0,R-sq 數值下降了一點,GCV 數值上升了,說明這個模型不如前面的 gam_4 來的 好 ## 畫出 gam_5 的圖像



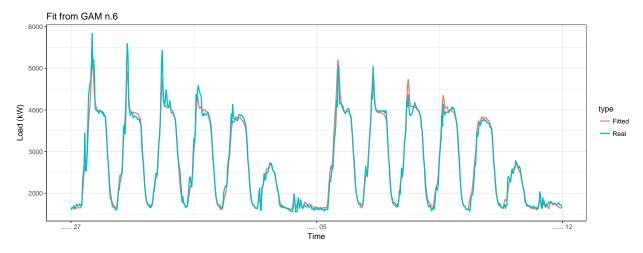
呼 \sim ,這回是最後一個招數了,這裡再多嘗試一個 tensor product interactions 方法,並設定 **full =** TRUE 來設定更加嚴格的懲罰條件

[1] 0.9738273

```
summary(gam_6)$sp.criterion
```

```
## GCV.Cp
## 32230.68
```

畫圖分析 gam_6 的效果



這個圖就看上去漂亮很多了

這麽多模型,要怎麼看誰的效果最好呢?交給萬能的 AIC 來解決吧

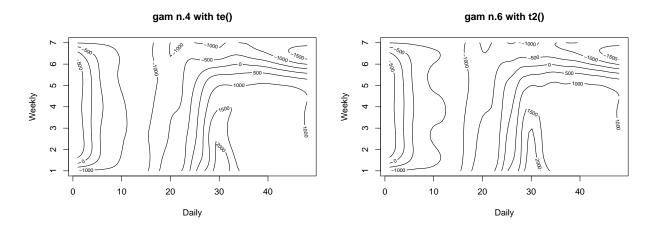
```
AIC(gam_1, gam_2, gam_3, gam_4, gam_5, gam_6)
```

```
## df AIC
## gam_1 17.46996 10248.993
## gam_2 30.70080 9415.768
## gam_3 25.65709 9492.545
## gam_4 121.41166 8912.611
## gam_5 115.80849 8932.746
## gam_6 100.12005 8868.628
```

很明顯 gam_4, gam_5, gam_6 是優勝組, 其中 gam_6 是最好的那一個, 緊隨其後的是 gam_4

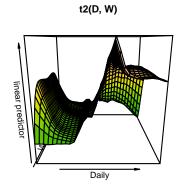
接下來就 gam_4, gam_6 這幾個模型單獨畫圖看看結果是什麼樣的吧

```
layout(matrix(1:2, nrow = 1))
plot(gam_4, rug = FALSE, se = FALSE, n2 = 80, main = "gam n.4 with te()")
plot(gam_6, rug = FALSE, se = FALSE, n2 = 80, main = "gam n.6 with t2()")
```



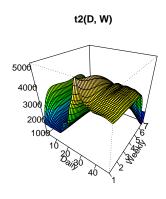
這些類似等高線的圖像顯示了各個模型對 Weekly 和 Daily 的反應情況。gam_4, gam_6 類似,但 gam_6 的圖形有更多的波動性,說明它的靈敏程度更好。

最後在這個章節結束前,看看怎麼把 gam_6 的圖像畫得更好看吧。首先使用 mgcv 套件包裡 的 vis.gam 功能



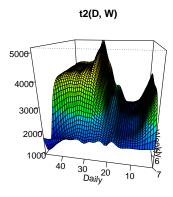
可以看出,平日的用電量比週末來得多很多,每天的工作時間用電量比較大,禮拜一到禮拜四的下午 3 點 左右是用電最高峰時期。

加入不使用 contour.col 選項, 還可以作一個 3D 版本的圖



轉換一下視角

```
vis.gam(gam_6, n.grid = 50, theta = 190, phi = 20, zlab = "",
    ticktype = "detailed", color = "topo", main = "t2(D, W)")
```



3. 分析解釋變量的重要情況

現在來看看減少剔除部分解釋變數對模型的有什麼樣的影響

這回剔除 Daily 這個因素

[1] 0.2502016

```
summary(gam_6W)$sp.criterion
```

```
## GCV.Cp
## 791454.6
```

可以看到這下效果更糟糕了

保持著嚴謹的態度,使用 anova 來比較這三個模型的差異

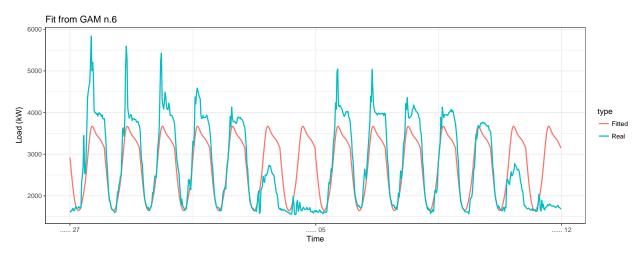
先看看剔除 Weekly 會造成怎麼樣的差異

```
anova(gam_6, gam_6D, test="F")
## Analysis of Deviance Table
##
## Model 1: Load ~ t2(Daily, Weekly, k = c(period, 7), bs = c("cr", "ps"),
      full = TRUE)
##
## Model 2: Load ~ t2(Daily, k = period, bs = "cr", full = TRUE)
    Resid. Df Resid. Dev
                              Df
                                                 F
                                                      Pr(>F)
                                   Deviance
##
       550.77
## 1
                15740821
## 2
       661.13 339050831 -110.37 -323310010 106.61 < 2.2e-16 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
```

再看看剔除 Daily 會造成怎麼樣的差異

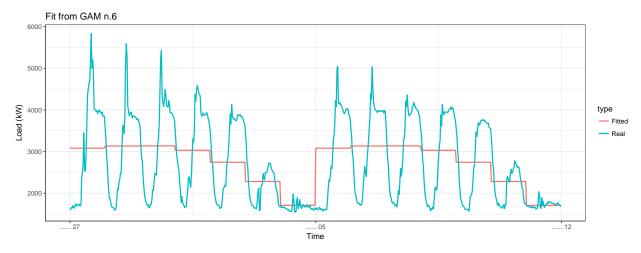
```
anova(gam_6, gam_6W, test="F")
## Analysis of Deviance Table
##
## Model 1: Load ~ t2(Daily, Weekly, k = c(period, 7), bs = c("cr", "ps"),
      full = TRUE)
## Model 2: Load ~ t2(Weekly, k = 7, bs = "ps", full = TRUE)
    Resid. Df Resid. Dev
                           Df Deviance
                                             F
                                                   Pr(>F)
## 1
       550.77
                15740821
## 2
       667.88 526095056 -117.11 -510354235 158.6 < 2.2e-16 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
結果顯而易見, Weekly 因素和 Daily 因素缺一不可!
```

作圖展示不考慮 Weekly 因素的模型的擬合效果:



可以看出沒有考慮 Weekly 因素的話,預測結果不會體現週次不同所造成的用電起伏變化

作圖展示不考慮 Daily 因素的模型的擬合效果:

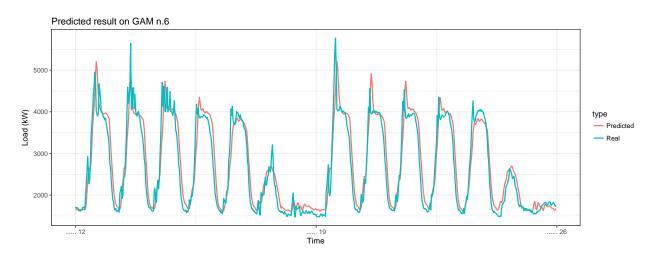


可以看出沒有考慮 Daily 因素的話,預測結果不會體現一天 24 小時內的用電起伏變化

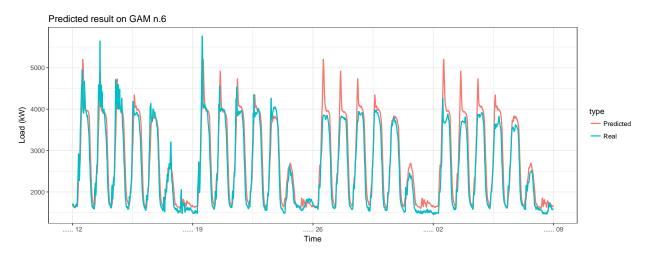
```
predWeek <- function(data, set_of_date){</pre>
  # Subsetting the dataset by dates
  data_train <- data[date %in% set_of_date]</pre>
  N <- nrow(data_train)</pre>
  window <- N / period # number of days in the train set
  # 1, ..., period, 1, ..., period - and so on for the daily season
  # Using feature "week_num" for the weekly season
  matrix_train <- data.table(Load = data_train[, value],</pre>
                            Daily = as.factor(rep(1:period, window)),
                            Weekly = as.factor(data_train[, week_num]))
  # Creation of the model
  lm_m <- lm(Load ~ 0 + Daily + Weekly + Daily:Weekly, data = matrix_train)</pre>
  # Creation of the forecast for one week ahead
  pred_week <- predict(lm_m, matrix_train[1:(7*period), -1, with = FALSE])</pre>
  return(as.vector(pred_week))
}
```

4. 預測電耗

最後,最振奮人心的——預測接下來兩周的用電量



預測接下來一個月的用電量



期末結束新增的部分:

定義 MAPE 函數

```
mape <- function(real, pred){
   return(100 * mean(abs((real - pred)/real)))
}</pre>
```

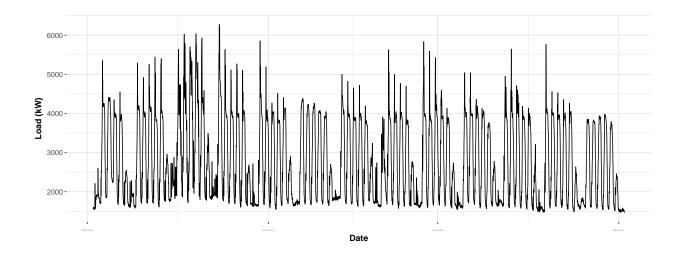
定義各個模型的評估標準(R-sq, GCV, MAPE):

定義各個模型的圖表分析函數

利用第一個季度的資料構建訓練集

```
data_new <- DT[(type == n_type[1] & date %in% n_date[1:91])]

ggplot(data_new, aes(date_time, value)) +
    geom_line() +
    theme(panel.border = element_blank(),
        panel.background = element_blank(),
        panel.grid.minor = element_line(colour = "grey90"),
        panel.grid.major = element_line(colour = "grey90"),
        panel.grid.major.x = element_line(colour = "grey90"),
        axis.text = element_text(size = 10),
        axis.title = element_text(size = 12, face = "bold")) +
    labs(x = "Date", y = "Load (kW)")</pre>
```



重新整理資料,新增前一天同時間的電耗和前一禮拜同時間的電耗

建立第一個模型

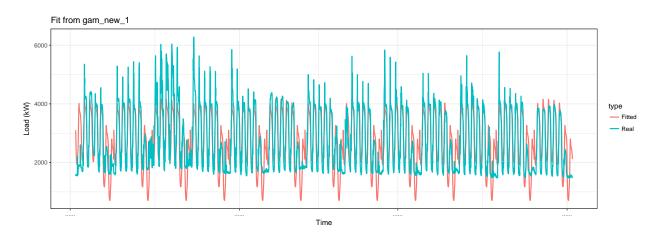
第一個模型的數據分析

```
eval_1 <- gam_eval(gam_new_1)
eval_1</pre>
```

RSQ GCV MAPE ## 1: 0.7194149 311287.5 18.89976

第一個模型的擬合狀況圖像

```
gam_plot(gam_new_1, "Fit from gam_new_1")
```



建立第二個模型

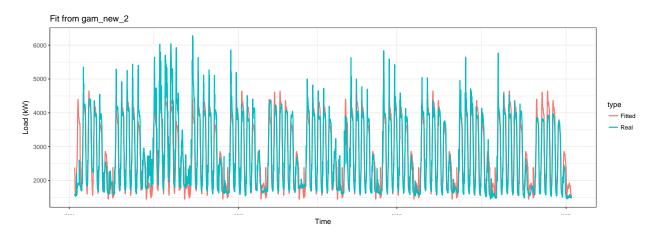
第二個模型的數據分析

```
eval_2 <- gam_eval(gam_new_2)
eval_2</pre>
```

RSQ GCV MAPE ## 1: 0.8487935 168039.3 10.62365

第二個模型的擬合狀況圖像

```
gam_plot(gam_new_2, "Fit from gam_new_2")
```



建立第三個模型

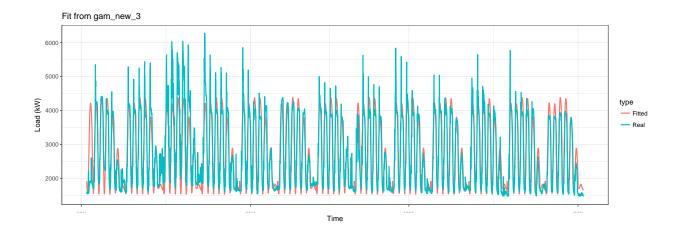
第三個模型的數據分析

```
eval_3 <- gam_eval(gam_new_3)
eval_3</pre>
```

```
## RSQ GCV MAPE
## 1: 0.8423209 175028.3 10.18985
```

第三個模型的擬合狀況圖像

```
gam_plot(gam_new_3, "Fit from gam_new_3")
```



建立第四個模型

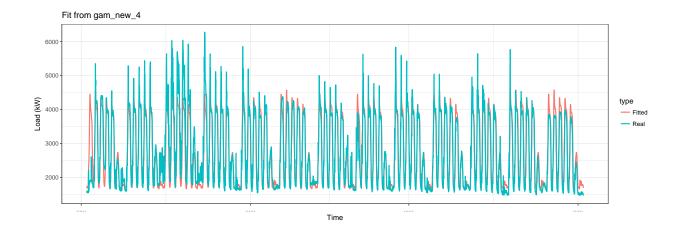
第四個模型的數據分析

```
eval_4 <- gam_eval(gam_new_4)
eval_4</pre>
```

```
## RSQ GCV MAPE
## 1: 0.8796766 135799.2 8.319575
```

第四個模型的擬合狀況圖像

```
gam_plot(gam_new_4, "Fit from gam_new_4")
```



建立第五個模型

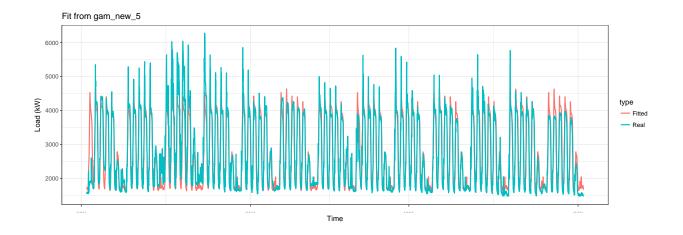
第五個模型的數據分析

```
eval_5 <- gam_eval(gam_new_5)
eval_5</pre>
```

```
## RSQ GCV MAPE
## 1: 0.8801601 135306 8.337419
```

第五個模型的擬合狀況圖像

```
gam_plot(gam_new_5, "Fit from gam_new_5")
```



建立第六個模型

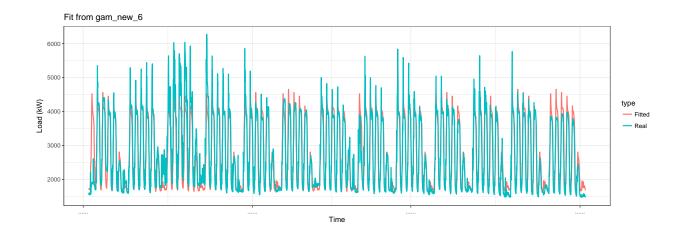
第六個模型的數據分析

```
eval_6 <- gam_eval(gam_new_6)
eval_6</pre>
```

```
## RSQ GCV MAPE
## 1: 0.8802681 134768.2 8.32655
```

第六個模型的擬合狀況圖像

```
gam_plot(gam_new_6, "Fit from gam_new_6")
```



構建第七個模型——不使用 smooth function 的 gam 模型:

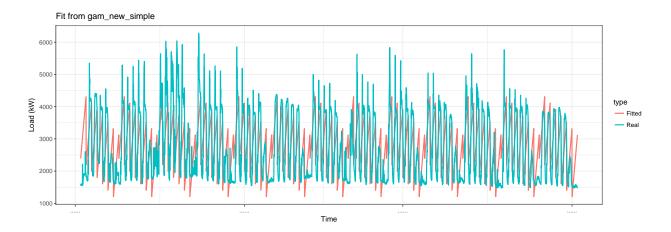
第七個模型的數據分析

```
eval_7 <- gam_eval(gam_new_simple)
eval_7</pre>
```

RSQ GCV MAPE ## 1: 0.4302044 629325.7 25.61359

第七個模型的擬合狀況圖像

gam_plot(gam_new_simple, "Fit from gam_new_simple")



建立第八個模型——只對 Daily 作 te smooth function

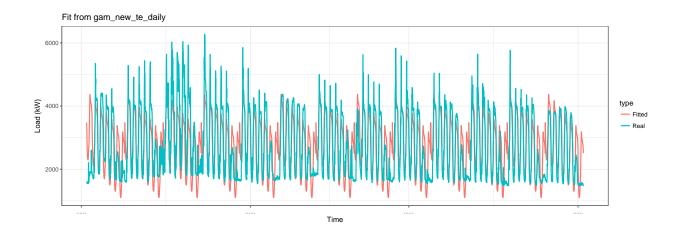
第八個模型的數據分析

```
eval_8 <- gam_eval(gam_new_te_daily)
eval_8</pre>
```

```
## RSQ GCV MAPE
## 1: 0.6366094 402558.4 20.44199
```

第八個模型的擬合狀況圖像

```
gam_plot(gam_new_te_daily, "Fit from gam_new_te_daily")
```



建立第九個模型——只對 Weekly 作 te smooth function

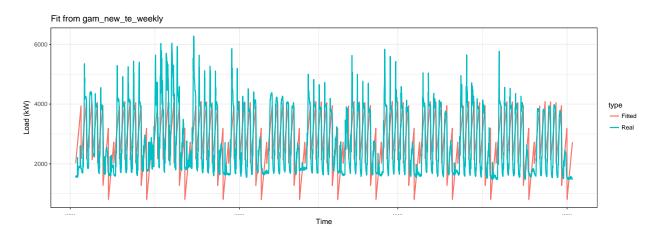
第九個模型的數據分析

```
eval_9 <- gam_eval(gam_new_te_weekly)
eval_9</pre>
```

RSQ GCV MAPE ## 1: 0.5124041 539142 24.279

第九模型的擬合狀況圖像

```
gam_plot(gam_new_te_weekly, "Fit from gam_new_te_weekly")
```



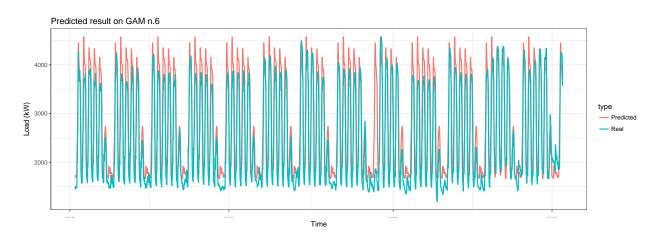
用表格查看 9 個模型的數據分析

```
eval_table <- bind_rows(eval_1, eval_2, eval_3, eval_4, eval_5, eval_6, eval_7, eval_8, eval_9)
all_aic <- AIC(gam_new_1, gam_new_2, gam_new_3, gam_new_4, gam_new_5, gam_new_6, gam_new_simple, g
eval_table[, AIC :=all_aic]
eval_table <- data.table(MODELS=c("gam_new_1 ", "gam_new_2", "gam_new_3", "gam_new_4", "gam_new_5"
eval_table</pre>
```

```
##
                 MODELS
                              RSQ
                                       GCV
                                                MAPE
                                                          AIC
             gam_new_1 0.7194149 311287.5 18.899761 67646.26
## 1:
              gam_new_2 0.8487935 168039.3 10.623654 64953.21
## 2:
## 3:
              gam_new_3 0.8423209 175028.3 10.189855 65131.27
## 4:
              gam_new_4 0.8796766 135799.2 8.319575 64020.79
              gam_new_5 0.8801601 135306.0 8.337419 64004.82
## 5:
## 6:
              gam_new_6 0.8802681 134768.2 8.326550 63987.99
         gam_new_simple 0.4302044 629325.7 25.613586 70721.15
## 7:
       gam_new_te_daily 0.6366094 402558.4 20.441993 68769.43
## 9: gam_new_te_weekly 0.5124041 539142.0 24.278996 70045.54
```

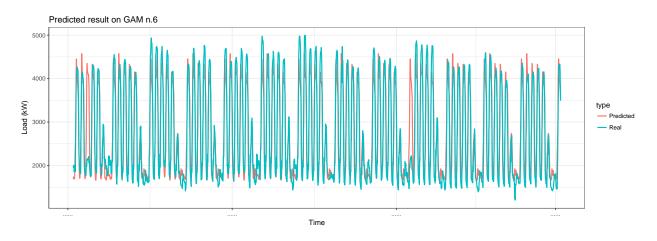
使用第四個 model 預測當年第二個季度

```
data_test_2qt <- DT[(type == n_type[1] & date %in% n_date[92:183])]
matrix_test_2qt <- data.table(Load = data_test_2qt[, value],</pre>
```

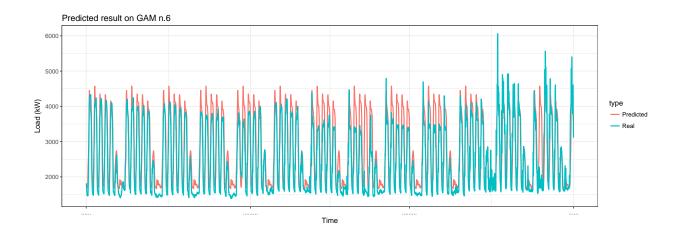


使用第四個 model 預測當年第三個季度

```
geom_line(size = 0.8) +
theme_bw() +
labs(x = "Time", y = "Load (kW)",
    title = "Predicted result on GAM n.6")
```



使用第四個 model 預測當年第四個季度



計算 prediciton 的 MAPE

```
mape_2qt <- mape(matrix_test_2qt[1:(7*period)]$Load, pred_2qt)
mape_3qt <- mape(matrix_test_3qt[1:(7*period)]$Load, pred_3qt)
mape_4qt <- mape(matrix_test_4qt[1:(7*period)]$Load, pred_4qt)
mapes <- cbind(mape_2qt, mape_3qt, mape_4qt)
mapes</pre>
```

```
## mape_2qt mape_3qt mape_4qt
## [1,] 12.01464 14.89136 12.93795
```